Sesión 1

Introducción

Carlos César Sánchez Coronel

CÁLCULO Y ÁLGEBRA LINEAL PARA IA

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Representación de datos en IA

- Los modelos de IA operan con números organizados en estructuras matemáticas.
- **Escalar**: un solo número real (temperatura, bias).

$$x = 5{,}2$$

- **Vector**: lista ordenada (punto en espacio de características).

$$\mathbf{x} = [2{,}5, 1{,}8, 3{,}0] \quad \text{(altura, peso, edad)}$$

- **Matriz**: tabla bidimensional (imagen en grises, pesos de una capa).

$$\mathbf{X} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$$

- **Tensor**: generalización a más dimensiones (lote de imágenes a color).

$$\mathcal{T} \in \mathbb{R}^{32 \times 64 \times 64 \times 3}$$

Ejemplos en problemas de IA

Clasificación de imágenes

- Entrada: tensor $\mathcal{T}$ de dimensiones (batch, alto, ancho, canales).
- Pesos de una capa convolucional: tensor 4D.

Procesamiento de texto (embeddings)

- Cada palabra se representa como un vector (embedding).
- Una frase es una matriz de (largo_frase, dim_embedding).

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Funciones como "cajas negras" en IA

Definición

Una función $f : X \to Y$ asigna a cada entrada una salida.

- En IA, los modelos son funciones complejas aprendidas de datos.
- Ejemplo: red neuronal que clasifica imágenes: $\mathbf{y} = f(\mathbf{x})$, donde $\mathbf{x}$ es un tensor de píxeles.

Tipos de funciones y su rol en IA

Lineales ($f(x) = mx + b$)

- Regresión lineal, capas fully-connected.

Polinomiales ($f(x) = a_n x^n + \dots$)

- Aproximación de funciones, sobreajuste.

Exponenciales (e^x, a^x)

- Softmax, pérdida cross-entropy, modelos de crecimiento.

Logarítmicas ($\ln x$)

- Entropía, verosimilitud, log-loss.

Trigonométricas ($\sin x$, $\cos x$)

- Positional encodings en Transformers, procesamiento de señales.

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

¿Por qué necesitamos activaciones no lineales?

- Sin no linealidades, una red profunda sería equivalente a una regresión lineal.
- Las activaciones permiten aprender relaciones complejas.

Principales funciones de activación

Sigmoide

$$\sigma(x) = \frac{1}{1+e^{-x}} \in (0,1)$$

Tanh

$$\tanh(x) \in (-1,1)$$

ReLU

$$\text{máx}(0,x)$$

Leaky ReLU

$$\text{máx}(\alpha x, x), \ \alpha \approx 0{,}01$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

GELU

$$x\Phi(x)$$

Softmax y aplicaciones

Softmax

Convierte un vector de logits en una distribución de probabilidad:

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

- **Uso**: capa final en clasificación multiclase (ej. reconocimiento de dígitos, clasificación de imágenes).
- Las salidas son positivas y suman 1.

Ejemplo de cálculo con softmax

Logits de una red: $\mathbf{z} = [2{,}0, 1{,}0, 0{,}1]$

$$e^{2{,}0} = 7{,}389, \quad e^{1{,}0} = 2{,}718, \quad e^{0{,}1} = 1{,}105$$
$$\text{suma} = 7{,}389 + 2{,}718 + 1{,}105 = 11{,}212$$
$$\text{softmax} = [0{,}659, 0{,}242, 0{,}099]$$

La clase más probable es la primera con 65.9 %.

Propiedades clave de las activaciones

- **Sigmoide** y **Tanh** saturan para $|x|$ grandes $\rightarrow$ gradientes pequeños (desvanecimiento).
- **ReLU** no satura en $x > 0$, eficiente, pero puede morir si $x < 0$ siempre.
- **GELU** combina ReLU y dropout, usada en Transformers (BERT, GPT).

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

¿Qué miden las funciones de pérdida?

- Cuantifican la diferencia entre la predicción del modelo y el valor real.
- Son la base del entrenamiento (gradiente descendente).

Pérdidas para regresión

MSE (Error Cuadrático Medio)

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- Penaliza más los errores grandes (sensible a outliers).
- Diferenciable, fácil de optimizar.

MAE (Error Absoluto Medio)

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- Más robusto a outliers.

Pérdidas para clasificación

Cross-Entropy binaria

$$\mathrm{BCE} = -\frac{1}{n}\sum_i \left[y_i \log \hat{y}_i + (1 - y_i)\log(1 - \hat{y}_i)\right]$$

Cross-Entropy multiclase

$$\mathrm{CE} = -\sum_i \sum_{k=1}^{K} y_{i,k} \log \hat{y}_{i,k}$$

- Castiga fuertemente predicciones erróneas con alta confianza.

Pérdidas especializadas

- **Hinge Loss** (SVM): $\text{máx}(0, 1 - y_i\hat{y}_i)$ con $y_i \in \{-1, 1\}$.
- **Focal Loss**: para clases desbalanceadas (ej. detección de objetos).

$$\text{FL} = -(1 - \hat{y}_i)^\gamma \log(\hat{y}_i)$$

- **Triplet Loss**: para aprendizaje de representaciones (face recognition).

$$\mathcal{L} = \text{máx}(0, d(a, p) - d(a, n) + \alpha)$$

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Comparando vectores en IA

- Miden qué tan cercanos son dos puntos en el espacio de características.
- Aplicaciones: búsqueda semántica, clustering, sistemas de recomendación.

Métricas comunes

Producto punto

$$\langle \mathbf{u}, \mathbf{v} \rangle = \sum_i u_i v_i$$

Similitud de coseno

$$\cos\theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$$

Distancia Euclidiana (L2)

$$d_2 = \sqrt{\sum_i (u_i - v_i)^2}$$

Distancia Manhattan (L1)

$$d_1 = \sum_i |u_i - v_i|$$

Ejemplo de cálculo

Dados $\mathbf{u} = (1, 2, 3)$, $\mathbf{v} = (4, 5, 6)$

$$\begin{aligned}
\mathbf{u} \cdot \mathbf{v} &= 1 \cdot 4 + 2 \cdot 5 + 3 \cdot 6 = 32 \\
\|\mathbf{u}\|_2 &= \sqrt{1 + 4 + 9} = \sqrt{14} \approx 3{,}742 \\
\|\mathbf{v}\|_2 &= \sqrt{16 + 25 + 36} = \sqrt{77} \approx 8{,}775 \\
\cos\theta &= \frac{32}{3{,}742 \cdot 8{,}775} \approx 0{,}975 \\
d_2 &= \sqrt{9 + 9 + 9} = \sqrt{27} \approx 5{,}196 \\
d_1 &= 3 + 3 + 3 = 9
\end{aligned}$$

Kernel RBF

Radial Basis Function

$$K(\mathbf{u}, \mathbf{v}) = \exp\left(-\gamma \|\mathbf{u} - \mathbf{v}\|^2\right)$$

- Proyecta a un espacio de mayor dimensión implícitamente.
- Usado en SVM y procesos Gaussianos.
- Mide similitud basada en distancia; γ controla la suavidad.

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Lógica y árboles de decisión

- La lógica proposicional maneja valores verdadero/falso y conectores (AND, OR, NOT).
- En IA, aparece en:
  - **Árboles de decisión**: cada nodo es una condición lógica sobre una característica.
  - **Sistemas basados en reglas**.
  - **Programación lógica** (Prolog).

Ejemplo: Árbol de decisión para aprobar préstamo

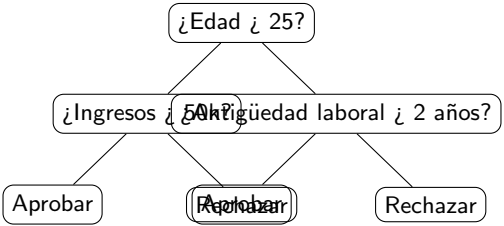

Las hojas contienen la decisión final.

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Notación compacta para operaciones repetitivas

Sumatoria

$$\sum_{i=1}^{n} x_i = x_1 + x_2 + \cdots + x_n$$

Ejemplo en una neurona:

$$z = \sum_{i=1}^{n} w_i x_i + b$$

Productoria

$$\prod_{i=1}^{n} x_i = x_1 \cdot x_2 \cdots x_n$$

Ejemplo: probabilidad conjunta de eventos independientes:

$$P(X_1, \ldots, X_n) = \prod_{i=1}^{n} P(X_i)$$

Aplicaciones en IA

- Sumatorias: productos escalares, sumas de errores (MSE), sumas de log-verosimilitud.
- Productorias: multiplicación de probabilidades, modelos gráficos (HMM).

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Librerías esenciales

Fundamentales

- NumPy: tensores, álgebra lineal.
- SciPy: optimización, señales.
- Matplotlib/Seaborn: gráficos.
- SymPy: cálculo simbólico.

Machine Learning clásico

- Scikit-learn
- XGBoost, LightGBM, CatBoost

Deep Learning

- TensorFlow/Keras
- PyTorch
- JAX

Especializadas

- NLP: HuggingFace, NLTK, spaCy
- Visión: OpenCV, torchvision
- Audio: librosa
- Grafos: NetworkX, PyG

Entornos y herramientas

- **Jupyter Notebook / JupyterLab**: experimentación interactiva.
- **Google Colab**: GPU/TPU gratuitas.
- **VS Code**, **PyCharm**: editores.
- **Docker**: reproducibilidad.
- **Git**: control de versiones.

Ejemplo práctico: visualización de activaciones

```
import numpy as np
import matplotlib.pyplot as plt

x = np.linspace(-5,5,100)
plt.plot(x, 1/(1+np.exp(-x)), label='Sigmoide')
plt.plot(x, np.tanh(x), label='Tanh')
plt.plot(x, np.maximum(0,x), label='ReLU')
plt.legend()
plt.title('Funciones de activación')
plt.grid(True)
plt.show()
```

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Modelo de una neurona

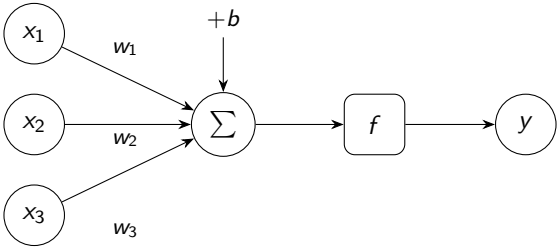

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right)$$

Contenido

1. Estructuras de Datos en IA
2. Funciones Elementales
3. Funciones de Activación
4. Funciones de Pérdida
5. Similitud y Distancia
6. Lógica Proposicional en IA
7. Sumatorias y Productorias
8. Python: Ecosistema para IA
9. Neurona Artificial
10. Resumen

Lo que hemos visto

- **Estructuras de datos**: escalares, vectores, matrices, tensores.
- **Funciones elementales** y su rol en IA.
- **Funciones de activación**: sigmoide, tanh, ReLU, softmax, GELU.
- **Funciones de pérdida**: MSE, MAE, cross-entropy, focal loss, triplet loss.
- **Métricas de similitud**: producto punto, coseno, L1, L2, kernel RBF.
- **Lógica proposicional** y árboles de decisión.
- **Sumatorias y productorias**: notación y aplicaciones.
- **Python**: librerías y herramientas para IA.

Conexión con el resto del curso

- Estos conceptos son la base para entender modelos:
  - Regresión lineal y logística.
  - Redes neuronales y backpropagation.
  - Transformers y mecanismos de atención.
  - Sistemas de recomendación y clustering.
- En las próximas sesiones profundizaremos en cálculo diferencial y álgebra lineal aplicados.

¡Gracias!